DT y RBFSampler con Digits

June 12, 2018

1 Clasificación con DecisionTree usando RBFSampler con el dataset Digits de scikit-learn

http://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_digits.html

1.1 Información del dataset

Casi 1800 imágenes de 8x8 con los dígitos 0..9. Cada píxel se representa con un número entre 0..15, que representa un color en la escala de grises.

En este notebook se hará el training con los datos sacados de RBFSampler. En algunos ejemplos de scikit-learn, normalizan este dataset (dividen cada fila por 16 y luego le restan la media). En este notebook el training se hará directamente con los datos de RBFSampler, sin hacer ningún tipo de preprocesado. Para ver el mismo código pero normalizando, estará en otro notebook.

```
In [1]: from sklearn.datasets import load_digits
        from sklearn.tree import DecisionTreeClassifier
        from sklearn.kernel_approximation import RBFSampler
In [2]: import math
        import numpy as np
In [19]: import matplotlib.pyplot as plt
In [3]: digits = load_digits()
In [4]: sampler = RBFSampler(n_components = 1000)
In [5]: data = digits.data
        target = digits.target
        N = data.shape[0] #N: cantidad de instancias, 1797
        prop_train = 2 / 3
        N_train = math.ceil(N * prop_train)
        N_{test} = N - N_{train}
In [6]: sampler.fit(data)
        data = sampler.transform(data)
```

1.2 Hacer varias ejecuciones y hacer la media

```
In [8]: n_runs = 10
        train scores = []
        test_scores = []
In [9]: for i in range(n_runs):
            clf = DecisionTreeClassifier()
            clf.fit(data_train, target_train)
            train_score = clf.score(data_train, target_train)
            test_score = clf.score(data_test, target_test)
            train_scores.append(train_score)
            test_scores.append(test_score)
In [10]: print("Mean of test scores:",np.mean(test_scores))
         print("Mean of train scores:", np.mean(train_scores))
Mean of test scores: 0.10784641068447413
Mean of train scores: 1.0
In [11]: print("Standard deviation of test scores:",np.std(test_scores))
         print("Standard deviation of train scores:",np.std(train_scores))
Standard deviation of test scores: 0.008286927309509756
Standard deviation of train scores: 0.0
```

1.3 £Como cambia accuracy si incrementamos la cantidad de features extraídas?

```
In [16]: components = 40 * np.arange(70) + 50
         scores = []
         n_runs = 7
In [17]: for comp in components:
             sampler = RBFSampler(n_components=comp)
             sampler.fit(data)
             dat = sampler.transform(data)
             dat_train = dat[:N_train]
             dat_test = dat[N_train:]
             clf = DecisionTreeClassifier()
             clf.fit(dat_train, target_train)
             sc = 0
             for i in range(n_runs):
                  sc += clf.score(dat_test, target_test)
             sc /= n_runs
             scores.append(sc)
In [20]: plt.plot(components, scores)
         plt.xlabel("Number of components used")
         plt.ylabel("Accuracy achieved")
Out[20]: Text(0,0.5,'Accuracy achieved')
          0.375
          0.350
          0.325
       Accuracy achieved
          0.300
          0.275
          0.250
          0.225
          0.200
                           500
                                              1500
                                    1000
                                                         2000
                                                                   2500
```

Number of components used

Maximum achieved score: 0.3689482470784641 Minimum achieved score: 0.19365609348914856

1.3.1 Conclusiones

El modelo parece ajustar muy bien, pero no generaliza nada. La cantidad de features extraídas parece ayudar a incrementar la precisión, aunque tiene mucha varianza.